


Apache Kafka

Daniel, Fabian, Hauke und Tom

Modellierung von Informationssystemen
Department Informatik
HAW Hamburg

01. Dezember 2017



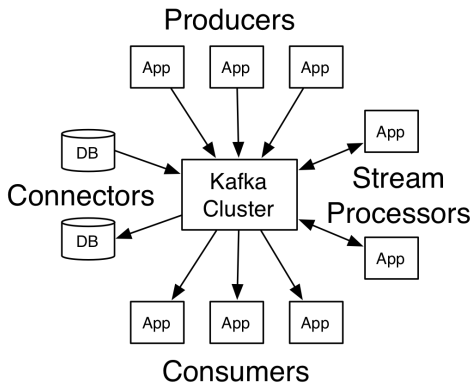
1 Konzept

- Einführung
- Grundlagen (Queue & Topic)
- Kafka Topic
- Eigenschaften von Kafka
- Performance Analyse

2 Tutorial

- Quickstart
- Properties
- Kafka Clients
- Twitter App

Was ist Apache Kafka?



Apache Kafka ist eine verteilte skalierbare Streaming Plattform.

Graphics based on [1]

Eigenschaften

Kafka ...

- ist ein Message Queuing System
- kann Nachrichten speichern
- kann Nachrichten verarbeiten
- kann all das in Echtzeit

Motivation




Abbildung 1.1: Kafka and Hadoop [2]

Unternehmen und Use Cases



Operational Metrics



OpenSOC (Security Operations Center)



Real-time Monitoring and Event-processing Pipeline




Log Delivery System




Part of Storm Stream Processing Infrastructure

Queue



Graphics based on [3]

Topic




Graphics based on [3]

Zusammenfassung


Bisher:

- Queueing
 - ▶ Nachricht 1:1 Consumer
 - ▶ Nachrichtenverarbeitung skaliert
 - ▶ Nachricht abgerufen = Nachricht weg
- Topic
 - ▶ Nachrichten 1:N Consumer
 - ▶ Nachrichten werden verteilt
 - ▶ Skaliert nicht

Kafka Topic



Kafka Topic




Kafka Topic

- Vereinigt klassischen Queue- und Topicsansatz
- Multi-Subscribe (0 bis n Consumer)
- Records in Topics werden persistent gehalten
- Topics benötigen eine Cleanup-Policy
 - ▶ Retention-Time
 - ▶ Retention-Size
 - ▶ Log-Compaction
- Guarantees
 - ▶ Reihenfolge der Records wird eingehalten
 - ▶ Consumer sehen die Einträge wie im Log gespeichert
 - ▶ N-1 Serverausfälle bei N Replikationen ohne Datenverluste

Partitionen


- Jedes Topic besteht aus $1..n$ Partitionen
- Eigenschaften von Partitionen
 - ▶ Records sind geordnet
 - ▶ Nicht-Veränderbare Sequenz von Records
 - ▶ Records können nur angehängt werden
- Records werden über `offset` identifiziert
- Records werden nach Cleanup-Policy entfernt
- Lesezugriff auf Records in Partitionen
 - ▶ Aufsteigend sequentieller Zugriff ist Standard
 - ▶ Wahlfreier Zugriff auf Records auch möglich

Partitionen



Graphics based on [1]

Partitionen



Graphics based on [1]

Partitionen

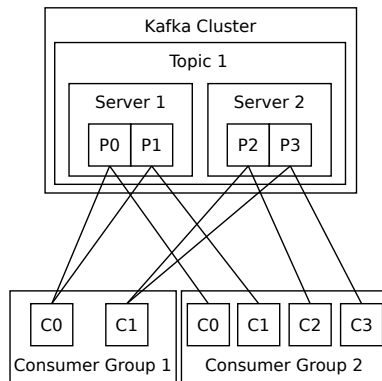
Verteilung der Partitionen unterstützt

- Skalierung
Topic kann durch Partitionen einfach auf mehrere Server verteilt werden.
- Parallele Verarbeitung
 - ▶ Load Balancing
 - ▶ Ordering Guarantees

Kafka als Nachrichtensystem

Consumer Groups

- Nachrichtenverarbeitung in Gruppen
- Mehrere Consumer werden in einer Gruppe organisiert
- Kombiniert Queueing und Publish-Subscribe



Graphics based on [1]

Kafka als Speichersystem

Kafka as a Storage System

"Kafka [is] a kind of special purpose distributed filesystem dedicated to high-performance, low-latency commit log storage, replication, and propagation." [1]

- Entkopplung von Consumer und Producer sorgt für Speicherbedarf
- Daten werden immer persistent gehalten
 - ▶ Kafka arbeitet somit *nicht* In-Memory
- Daten können repliziert werden

Kafka für Stream Processing

- Anforderung: Streamverarbeitung in *Echtzeit*!
- Ein Stream Processor
 - ▶ nimmt kontinuierlich Daten aus einem *Input* Topic,
 - ▶ bearbeitet die Daten und
 - ▶ schreibt kontinuierlich Daten in ein *Output* Topic

Kafka für Stream Processing - Stream API

- Stream API wird für nicht-triviales Stream Processing angeboten, z.B. zur Aggregation oder Joins von Streams.
- Stream API unterstützt
 - ▶ *Exactly-once* Verarbeitung von Daten
 - ▶ Statusbehaftete Operationen, wie Joins und Aggregationen über Bereiche
 - ▶ Erneute Verarbeitung von Daten, wenn sich die Operation ändert
 - ▶ *One-record-at-a-time Processing*, um Verarbeitungslatenz im Millisekundenbereich garantieren zu können

Performance Analyse




Abbildung 1.2: Performance Analyse – Durchsatz vs Datengröße [4]

Zusammenfassung

- geeignet für:
 - ▶ Bearbeitet die Daten
 - ▶ Schreibt kontinuierlich Daten in ein Topic

Gibt es bisher Fragen?

Tutorial

1 Konzept

- Einführung
- Grundlagen (Queue & Topic)
- Kafka Topic
- Eigenschaften von Kafka
- Performance Analyse

2 Tutorial

- Quickstart
- Properties
- Kafka Clients
- Twitter App

Quickstart

- Download Kafka [5]

```
$ tar -xzf kafka_2.11-1.0.0.tgz
$ cd kafka_2.11-1.0.0
```

```
$ bin/zookeeper-server-start.sh config/zookeeper.
  properties
$ bin/kafka-server-start.sh config/server.properties
```

Quickstart

```
$ bin/kafka-topics.sh --create --zookeeper localhost
:2181 --replication-factor 1 --partitions 1 --
topic test
$ bin/kafka-console-producer.sh --broker-list
localhost:9092 --topic test
> This is a message
> This is another message
```

```
$ bin/kafka-console-consumer.sh --bootstrap-server
localhost:9092 --topic test --from-beginning
> This is a message
> This is another message
```

Producer Properties

Name	Beschreibung	Typ
batch-size	Anzahl an Nachrichten die innerhalb eines Batches ins Cluster gepusht werden (asynchrone Kommunikation)	Integer
broker-list/ bootstrap.servers	Host- und Portliste zur Verbindung mit dem Cluster	Liste von Strings
message-send-max-retries	Maximale Anzahl an Versuchen das Datum an den Broker zu pushen, bevor der Producer es dropped	Integer
topic	Topic unter welches die Daten ins Cluster gepusht werden	String

Tabelle 1: Beispiele für Producer Properties [6]

Consumer Properties

Name	Beschreibung	Typ
blacklist	Blacklisten von Topics die nicht aboniert werden sollen	Liste von Strings
bootstrap.server/ bootstrap.servers	Host und Port zur Verbindung mit dem Cluster	String
from-beginning	Hole die erste Nachricht im Log, sofern der Offset nicht definiert wurde	-
topic	Topic unter welchem die Daten aus dem Cluster geholt werden sollen	String
whitelist	Whitelisten von Topics die aboniert werden sollen	Liste von Strings

Tabelle 2: Beispiele Consumer Properties [7]

Weitere Properties

- Broker Properties [8]
- Streams Properties [9]
- Topic Properties [10]
- Connect Config Properties [11]
- AdminClient Properties [12]

Kafka Clients

- Diverse Clients vorhanden [13]
 - ▶ Java, Python, Go, C/C++, .NET, Ruby, ...
- Kafka in Java geschrieben, daher der meiste Support

Twitter App [14]

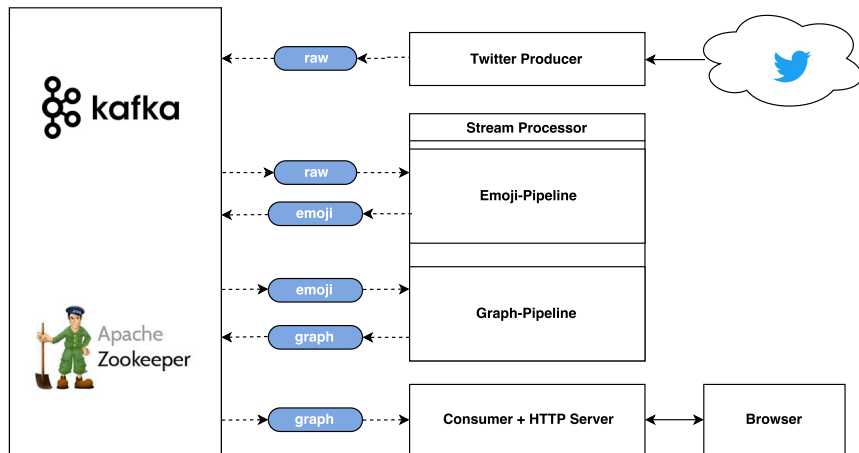


Abbildung 2.1: Architektur Twitter App

Python Producer

```
# Create Producer instance
p = Producer(**conf) #from config file

# connect to twitter
api = connect_to_twitter(config)
stream = api.GetStreamFilter(track=[search_term])
for line in stream:
    tweet = line_to_text(line)
    p.produce(topic, bytes(tweet, 'utf-8'))
```

Listing 1: Python Producer

Python Processor

```
# Kafka config
kafka_config.BOOTSTRAP_SERVERS = kafka_url
kafka_config.AUTO_OFFSET_RESET = 'earliest'

emoji_topic = src_topic + '-emoji'
target_topic = src_topic + '-chart'

with TopologyBuilder() as topology_builder1:
    topology_builder1. \
        source('tweets', [src_topic]). \
        processor('emoji', EmojiParserProcessor, 'tweets'). \
        sink('emojis', emoji_topic, 'emoji')

kafka_streams.KafkaStreams(topology_builder1, kafka_config).start
()

# close on termination
```

Listing 2: Python Processor

Python Consumer

```
# Create Consumer
c = Consumer(**conf) # external config

c.subscribe([topic])
running = True
print('Start polling..\nStop with ctrl-c..')
while running:
    msg = c.poll()
    try:
        if not msg.error():
            with open(filename, 'wb') as f:
                f.write(msg.value())
        else:
            pass
    except KeyboardInterrupt:
        running = False
```

Listing 3: Python Consumer

Screencast Demo

Vielen Dank für Eure Aufmerksamkeit!
Gibt es Fragen?

Literatur I

- [1] Apache Foundation. *Apache Kafka Documentation*. 2017. URL: <https://kafka.apache.org/> (besucht am 20.11.2017).
- [2] Jun Rao. *The value of Apache Kafka in Big Data ecosystem*. 2017. URL: <https://www.confluent.io/blog/the-value-of-apache-kafka-in-big-data-ecosystem/> (besucht am 20.11.2017).
- [3] Günther Bengel. *Grundkurs Verteilte Systeme – Grundlagen und Praxis des Client-Server und Distributed Computing*. Springer Vieweg, 2014. ISBN: 978-3-8348-1670-2.
- [4] Jay Kreps. *Benchmarking Apache Kafka: 2 Million Writes Per Second (On Three Cheap Machines)*. 2014. URL: <https://engineering.linkedin.com/kafka/benchmarking-apache-kafka-2-million-writes-second-three-cheap-machines> (besucht am 20.11.2017).

Literatur II

- [5] Apache Foundation. *Apache Download Mirror*. 2017. URL: https://www.apache.org/dyn/closer.cgi?path=/kafka/1.0.0/kafka_2.11-1.0.0.tgz (besucht am 30.11.2017).
- [6] Apache Foundation. *Apache Kafka Producer Properties*. 2017. URL: <https://kafka.apache.org/documentation/#producerconfigs> (besucht am 30.11.2017).
- [7] Apache Foundation. *Apache Kafka Consumer Properties*. 2017. URL: <https://kafka.apache.org/documentation/#newconsumerconfigs> (besucht am 30.11.2017).
- [8] Apache Foundation. *Apache Kafka Broker Properties*. 2017. URL: <https://kafka.apache.org/documentation/#brokerconfigs> (besucht am 30.11.2017).

Literatur III

- [9] Apache Foundation. *Apache Kafka Streams Properties*. 2017.
URL: <https://kafka.apache.org/documentation/#streamsconfigs>
(besucht am 30.11.2017).
- [10] Apache Foundation. *Apache Kafka Topic Properties*. 2017.
URL: <https://kafka.apache.org/documentation/#topicconfigs>
(besucht am 30.11.2017).
- [11] Apache Foundation. *Apache Kafka Connect Config Properties*. 2017. URL: <https://kafka.apache.org/documentation/#connectconfigs>
(besucht am 30.11.2017).

Literatur IV

- [12] Apache Foundation. *Apache Kafka AdminClient Properties*. 2017. URL: <https://kafka.apache.org/documentation/#adminclientconfigs> (besucht am 30.11.2017).
- [13] Apache Foundation. *Clients - Apache Kafka*. 2017. URL: <https://cwiki.apache.org/confluence/display/KAFKA/Clients> (besucht am 30.11.2017).
- [14] Daniel Sarnow u. a. *MI-Präsentation und Tutorial über Apache Kafka*. 2017. URL: <https://github.com/DanSar/minf-mi-kafka> (besucht am 30.11.2017).